陈思添

Phd Student | 2000.04 | 男
csstchen@comp.hkbu.edu.hk
+852 55146896
个人主页：https://steam009.github.io/

研究兴趣

本人的研究兴趣聚焦于大规模机器学习系统（MLSys）与软硬件协同设计，致力于打破万亿级模型在真实工业场景下面临的**"内存墙"与通信瓶颈**。具体而言，我深耕于**推荐系统（RecSys）与大规模向量检索（ANNS/RAG）**的底层系统优化，通过存内计算（PIM）、模型量化压缩以及基于智能网卡（SmartNIC）的分布式计算卸载等系统级技术，大幅降低模型推理延迟与训练通信开销。我期望能将这些底层软硬协同的优化经验应用于工业界，构建高吞吐、低延迟、高性价比的 AI 基础架构。

教育背景

香港浸会大学，计算机科学，博士 2024.9 - 2028.6

- 导师：周池 (https://amelieczhou.github.io/) 中国，香港

深圳大学，计算机科学与技术，本科 2019.9 - 2023.6

- 平均绩点：4.05/4.50 （top 5%）、计算机与软件学院优秀毕业生、学习之星二等奖 * 3、永旺奖学金 中国，深圳

过往经历

Summer School of Data Science, Learning and Optimization (DataSLO) 2025.6

- the University for Foreigners of Perugia 意大利，佩鲁贾
- 描述：参加了数据科学、机器学习和优化的暑期学校，学习了相关领域的最新研究进展，并与来自世界各地的研究人员进行了交流。

香港浸会大学，研究助理 2023.9 - 2024.9

- 香港浸会大学 中国，香港
- 描述：主要研究方向为加速推荐系统的推理过程，利用存内计算和模型压缩等技术，极大缓解了推荐系统在推理阶段的内存瓶颈问题，相关工作已被 DAC 2024 接收。

论文发表情况

计算机体系结构领域：

【应用方向：检索增强生成（RAG）】

UpANNS: Enhancing Billion-Scale ANNS Efficiency with Real-World PIM Architecture SC 2025 (CCF-A)

- **作者**：**Sitian Chen**[1], Amelie Chi Zhou[1], Yucheng Shi[1], Yusen Li[2], Xin Yao[3] ([1] 香港浸会大学, [2] 南开大学, [3] 华为香港理论部)
- **研究内容**：解决了 RAG 等技术中的核心 ANNS 算法在推理阶段的内存瓶颈问题，提出了一种基于存内计算的加速机制。实验表明该方法相比于 CPU 可以提供高达 4.3 倍的加速，相比于 GPU 可以提供高达 2.3 倍的能效提升。
- **关键词**：RAG, ANNS, Processor-in-Memory

【应用方向：推荐系统（Recommendation Systems）】

Near-Zero-Overhead Freshness for Recommendation Systems via Inference-Side Model Updates HPCA 2026 (CCF-A)

- **作者**：Wenjun Yu[1], **Sitian Chen**[1], Cheng Chen[2], Amelie Chi Zhou[1]([1] 香港浸会大学, [2] 字节跳动)
- **研究内容**：针对目前推荐系统在训推集群分离的架构下，模型更新导致的较大通信开销问题，提出了一种推理侧模型更新的方法，使得推荐系统能够以近零开销的方式保持模型的新鲜度。实验表明该方法相比于传统的 delta 更新方法可以提供 2 倍的加速和 0.24% 的精度提升。
- **关键词**：Recommendation Systems, Model Update, Freshness

GPAQuant: Accelerating Personalized Recommendation with Group-Wise and PIM-Aware Quantization TCAD 2026 (CCF-A)

- **作者**：**Sitian Chen**[1], Amelie Chi Zhou[1], Yusen Li[2], Min Si[3], Pavan Balaji[3]([1] 香港浸会大学, [2] 南开大学, [3]Meta)
- **研究内容**：针对推荐系统推理阶段的内存瓶颈问题，提出了一种 Group-wise 和存内计算感知的量化方法。实验表明该方法在模型精度损失较小的情况下，相比于传统的量化方法在推理阶段可以提供高达 3.4 倍的加速。
- **关键词**：Recommendation Systems, Quantization, Processor-in-Memory

UpDLRM: Accelerating Personalized Recommendation using Real-World PIM Architecture DAC 2024 (CCF-A)

- **作者**：**Sitian Chen**[1], Haobin Tan[2], Amelie Chi Zhou[1], Yusen Li[3], Pavan Balaji[4] ([1] 香港浸会大学, [2] 深圳大学, [3] 南开大学, [4]Meta)
- **研究内容**：针对推荐系统推理阶段的内存瓶颈问题，提出了一种基于存内计算的加速机制。实验表明该方法相比于 CPU/CPU-GPU 可以提供高达 4.6 倍的加速。
- **关键词**：Recommendation Systems, Processor-in-Memory

数据库领域:

SNI-GNN: SmartNIC-Assisted Full-Graph GNN Training with In-Network Embedding Prediction ICDE 2026 (CCF-A)

- **作者**：Guofan Yu[1], **Sitian Chen**[1], Zhenheng Tang[2], Xiaowen Chu[2], Amelie Chi Zhou[1]([1] 香港浸会大学, [2] 香港科技大学（广州））
- **研究内容**：提出了一种基于智能网卡（SmartNIC/DPU）的全图 GNN 训练系统，通过在数据路径上进行轻量级嵌入预测，显著降低了分布式训练中的通信开销，实现了通信效率与模型精度的双重优化。与当前最优的 SANCUS 和 NeutronTP 系统集成后，可将跨节点通信量减少 21-45%，端到端训练速度提升 1.3-3.6 倍。
- **关键词**：Graph Neural Networks, SmartNIC, Distributed Training

其他领域:

Low-Latency Video Conferencing System for Geo-Distributed Data Centers. IWQoS 2024 (CCF-B)

- **作者**：Yao Xiao, **Sitian Chen**, Amelie Chi Zhou, Shuhao Zhang, Yi Wang, Rui Mao, Xuan Yang.
- **关键词**：WebRTC, Geo-Distributed Data Centers

专业技能

C, C++, python, English: 雅思 6.5